Desenvolvimento de uma Rede Neural Convolucional para Classificação de Câncer de Mama

Felipe Alves de Vasconcelos[1], Dr. Robinson Luis de Souza Alves[2], Dr. Francisco Sales de Lima Filho[3]

[1]Diretoria Acadêmica de Gestão e Tecnologia da Informação (DIATINF) – Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Norte (IFRN) – Natal – RN

favasconcelos09@gmail.com, robinson.alves@ifrn.edu.br, sales.filho@escolar.ifrn.edu.br

Abstract. *Breast cancer is the most frequently diagnosed type of cancer in women, with at least 70,000 cases per year and a projected increase by 2024, according to data available in the Virtual Health Library (VHL). Early diagnosis achieved through mammograms significantly increases the probability of a complete cure due to the early initiation of treatment. However, early diagnosis may not occur due to a lack of specialized professionals or human error. This research proposes the creation of a Convolutional Neural Network (CNN) for breast cancer classification in mammogram images using Deep Learning. Its classification will be based on benign and malignant, using visual features created and extracted from the images by the network itself through training and validation with samples of other mammogram images. After analysis, the network will be able to accurately classify the patient's condition. Training was conducted with different architectures of the proposed network and different data processing strategies, performing a comparative analysis with other related works. The results obtained show that the same models used, adding the strategy of processing real data and images from an online dataset, achieved greater accuracy and fewer indications of false negatives and overfitting in precision, sensitivity, and AUC metrics.*
Keywords*: Breast cancer; Early diagnosis; Neural networks; Deep learning.*

Resumo. *O câncer de mama é o tipo de câncer mais diagnosticado em mulheres, com pelo menos mais de 70.000 casos por ano e tendência de crescimento em 2024, de acordo com dados disponíveis na Biblioteca Virtual em Saúde (BVS). O diagnóstico precoce alcançado em mamografias aumenta consideravelmente a probabilidade de cura completa, devido ao início do tratamento adiantado. Entretanto, este diagnóstico pode não vir de forma antecipada pela falta de profissionais especializados ou erros humanos. Esta pesquisa propõe a criação de uma Rede Neural Convolucional (CNN) para classificação de câncer de mama em imagens de mamografias através de Deep Learning. Sua classificação será feita entre benigno e maligno, baseada na análise de recursos visuais criados e extraídos das imagens pela própria rede por meio de treinamento e validação com amostras de outras imagens de mamografia, para então, após análise, estar apta para classificar de forma precisa a condição da paciente. Foram realizados treinamentos com diferentes arquiteturas da rede proposta e diferentes estratégias de tratamento de dados, realizando uma análise comparativa a outros trabalhos relacionados. Os resultados obtidos mostram que os mesmos modelos utilizados adicionando a estratégia de tratamento dos dados e imagens reais de um dataset online alcançaram maior acurácia e menores indícios de Falsos Negativos e Overfitting em métricas de Precisão, Sensibilidade e AUC.*

---

[1] Aluno(a) do curso de Tecnologia em Análise e Desenvolvimento de Sistemas do Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Norte.
[2] Professor(a) Doutorado do curso de Tecnologia em Análise e Desenvolvimento de Sistemas do Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Norte.
[3] Professor(a) Doutorado do curso de Tecnologia em Redes de Computadores do Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Norte.

***Palavras-chave**: Câncer de mama; Diagnóstico precoce; Redes Neurais; Deep learning.*

1. Introdução

Em 2024, [Silva, Nicollela e Pazello 2024] o câncer de mama foi o tipo de câncer mais diagnosticado em mulheres e se caracteriza como uma doença heterogênea com grande variação em suas características e manifestações clínicas. No Brasil, de 2023 a 2025 eram esperados cerca de 73.610 novos casos. Foi a primeira causa de morte por câncer em mulheres no país e a segunda em incidência. Segundo Bernardes *et al*. [2019], a principal forma de diagnóstico se dá pela análise de imagens de mamografia, pois além de sua, também há o fator de potencial avanço tecnológico por se tratar de análise de imagens digitais.

Nos últimos anos, o aprendizado profundo, no qual as redes neurais aprendem padrões diretamente a partir de dados brutos, alcançou um sucesso notável na classificação de imagens. Consequentemente, a pesquisa em IA médica floresceu em especialidades que dependem fortemente da interpretação de imagens, como radiologia, patologia, gastroenterologia e oftalmologia [Rajpurkar *et al*. 2022]. As redes neurais propostas para este trabalho para classificação de imagens têm como sua arquitetura a *Convolutional Neural Network* (CNN), ou Rede Neural Convolucional, utilizando o aprendizado através de *Deep Learning*.

O aprendizado profundo (*deep learning)* é uma subárea de estudo dentro da área de *machine learning*, que se caracteriza pela implementação de múltiplas camadas dentro de uma rede de Inteligência Artificial, assim tornando-a capaz de compreender padrões mais complexos e possibilitando tarefas de reconhecimento, detecção e classificação de objetos, além de outras tarefas partindo de grandes volumes de dados.

CNNs são arquiteturas de redes profundas especializadas em classificação de imagens com seus métodos de extração e aplicação de características em imagens durante seu treinamento, assim utilizando essas características para diferenciar e classificar uma imagem de outra, dependendo da característica encontrada na imagem. Essa extração de características é feita através da criação de *feature maps* baseados em elementos repetitivos nas imagens, justificando uma característica da classificação.

Com a metodologia que há hoje para identificação usando a mamografia sendo completamente dependente da análise humana dos profissionais, certas dificuldades são enfrentadas pelos médicos ao realizar o diagnóstico, como por exemplo a baixa sensibilidade em casos de tecido mamário denso ao tirar a imagem, dificultando ou causando erros no diagnóstico [Giess, Frost e Birdwell 2012].

1.1. Proposta

Sobre o uso de IA para análise mamográfica, foi comprovado por Aribal, Chan e YoonJH [*apud* Guerreiro *et al*. 2024] que Algoritmos de detecção assistida por computador baseados em IA apresentam desempenho equiparável, ou até superior, ao dos radiologistas, especialmente na redução de erros de percepção e interpretação. Essa abordagem tem o potencial de aprimorar a detecção precoce do câncer de mama, aumentando a confiabilidade e eficiência do processo diagnóstico.

Através das CNNs, o diagnóstico é feito pelas características únicas das imagens de cada classificação de forma imediata, assim contribuindo para o diagnóstico imediato no exame de mamografia e auxiliando a sanar dúvidas comuns que os humanos têm com imagens e suas interpretações. Portanto, seu uso como auxiliar para hospitais, ou como agentes mais diretos em outros locais de saúde onde pode-se não haver profissionais mastológicos, prova-se diante

as pesquisas que se torna uma grande ferramenta adicional para agregar ao diagnóstico precoce de câncer de mama.

Ao entender a crescente e o potencial de eficiência do uso de IAs nas diversas atividades do setor médico, é proposto por este trabalho o desenvolvimento de uma rede neural profunda com arquitetura CNN, para classificação de imagens de mamografias utilizando *Deep Learning*. A rede proposta teria utilidade apenas para prestar assistência aos profissionais de saúde em casos complexos de difícil diagnóstico.

1.2. Principais Contribuições

Este trabalho procura contribuir com o estudo científico através do aperfeiçoamento do trabalho feito previamente por Shabaan [2025], que tinha a proposta de desenvolver uma CNN utilizando o *dataset* criado por Awsaf49 [2021] e aplicando um pré-processamento das imagens com um algoritmo de equalização de histograma chamado CLAHE, para gerar maior nitidez em áreas elevadas das imagens representando possíveis regiões com lesões.

Apesar do trabalho finalizado, a proposta de utilização dos recursos não foi bem-sucedida nesta primeira versão. Ao analisar a versão 1, versão mais recente do trabalho, foi visto que o autor do trabalho utiliza imagens sintéticas geradas por um algoritmo aleatório para realizar o treinamento, a validação e os testes da rede, além disso, o algoritmo do CLAHE se encontra no trabalho, porém não é aplicado nas imagens utilizadas.

O aperfeiçoamento proposto neste trabalho será feito através da integração dos recursos propostos por Shabaan [2025] em seu trabalho, realizando o treinamento das redes propostas (com exceção da EfficientNetB3) com as imagens do *dataset* feito por Awsaf49 [2021] e integrando o pré-processamento das imagens com o algoritmo CLAHE proposto. Após a integração, serão feitos experimentos comparativos dos resultados do trabalho feito por Shabaan [2025], com o trabalho proposto utilizando os recursos idealizados para uso.

2. Revisão da Literatura

Agora, com o problema contextualizado e a solução bem definida, é crucial o aprofundamento dos recursos e conceitos utilizados dentro da pesquisa, comprovando com pesquisas relacionadas a sua eficácia e a sua importância para a pesquisa científica, e futuramente para os setores de saúde e tecnologia em conjunto.

2.1. Câncer de mama e Exames de Diagnóstico

O principal método de rastreamento do câncer de mama é através a mamografia, possibilitando o diagnóstico precoce e, consequentemente, a redução da mortalidade das mulheres com esse diagnóstico sendo alcançado em estágios iniciais com possibilidades de tratamento reais e promissoras [de Souza, et al. 2022].

Foi apontado que [Richard 2019] o diagnóstico de câncer de mama é um passo difícil para a paciente diagnosticada, que acaba por enfrentar problemas psicológicos, como depressão, ansiedade, estresse elevado, e problemas de autoestima causados pelos efeitos colaterais dos tratamentos usados para tratar esta doença.

Segundo experimento realizado por Richard [2019], pacientes com câncer de mama em estágio inicial tendem a ter menores sintomas psicológicos causados pelo diagnóstico, assim se

tratando de forma mais efetiva e não sofrendo tanto de maneira psicológica em relação a pacientes com estágio avançado. Portanto, a busca por melhor tratamento das pacientes diagnosticadas começa a partir de descobertas em estágios iniciais para melhor efetividade de tratamento físico e psicológico.

2.1.1. Mamografia

Mamografias são exames feitos através de análises de imagens feitas por profissionais que detectam lesões benignas ou malignas na região mamária da paciente. Segundo pesquisa a respeito da efetividade e importância da mamografia para o diagnóstico precoce [Tadesse, Begaw e Abdisa 2023] foi comprovado que a mamografia tem importância primordial para a detecção precoce de cânceres de mama, detectando cerca de 75% dos cânceres pelo menos um ano antes de serem sentidos. Mamografia de rastreio tem importância primordial em aumentar consideravelmente a chance de uma mulher ter tratamento bem-sucedido. Estudos tem mostrado que mamografias regulares podem reduzir o risco de câncer de mama em estágio final em mulheres de 80 anos ou mais.

Essas análises profissionais de imagens de mamografia estão sujeitas a resultados equivocados dos profissionais que as realizam, devido a falha dos equipamentos, ou falha humana que pode ocorrer independente do profissionalismo, causado principalmente pela similaridade entre imagens com densidades benignas e malignas.

Para essa análise mamográfica com posterior classificação concisa e padronizada das imagens pelos mastologistas, foi criado um sistema pelo Colégio Americano de Radiologia, adotado posteriormente pelo Colégio Brasileiro de Radiologia e Diagnóstico por Imagem (CBR), o *Breast Imaging and Reporting Data System* (BI-RADS). Sua função é disponibilizar informações às pacientes, aos seus familiares ou responsáveis, e aos profissionais de forma clara, padronizada e com valor considerável para todas as partes [Barazi e Gunduru 2023].

Entre as 7 categorias de classificação do BI-RADS, são envolvidas detecções de nódulos densos, cistos, calcificações, alterações relacionadas a implantes, cirurgias ou tratamentos, microcalcificações redondas, ovais ou ramificadas, lesões com suas devidas suspeitas de malignidade, tumores benignos ou malignos e densidades assimétricas entre as mamas.

É notável a quantidade de volumes e suas variáveis que podem ser encontrados em imagens de mamografias, podendo causar confusão ocasional do médico responsável por analisar e diagnosticar com precisão a benignidade ou malignidade das lesões e densidades das mamas. Esta dificuldade fica ainda mais visível ao se comparar duas imagens, uma de cada classificação.

Ao final deste parágrafo, é visto as representações visuais de imagens de mamografias, classificadas como benigno e maligno nas Figuras 1 e 2, respectivamente. As imagens foram retiradas do *dataset* utilizado para o desenvolvimento da rede neste trabalho, no repositório de *datasets* online Kaggle.

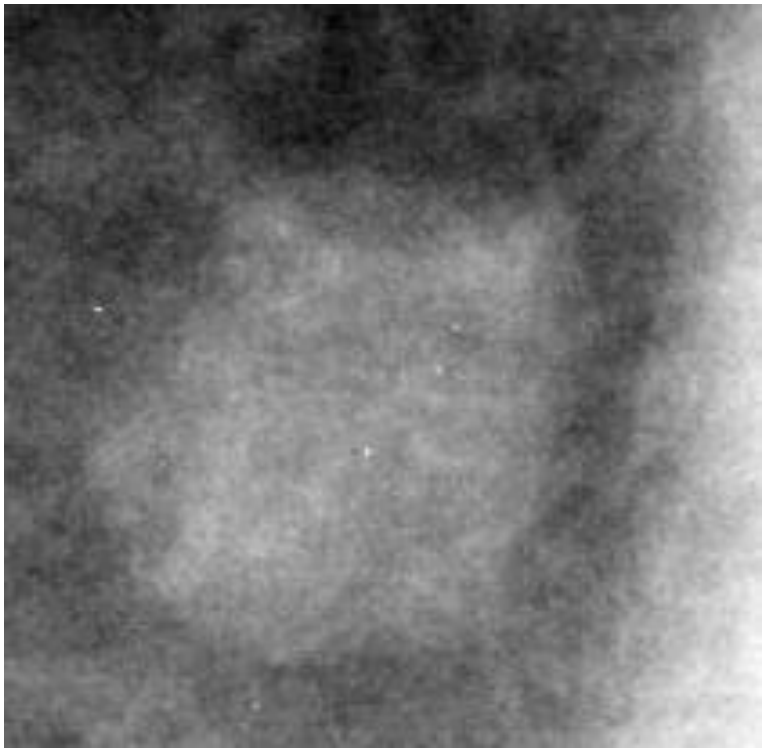

Figura 1. Imagem de mamografia classificada como BENIGNA

Fonte: https://www.kaggle.com/datasets/awsaf49/cbis-ddsm-breast-cancer-image-dataset. Acesso em: 13 ago. 2025.

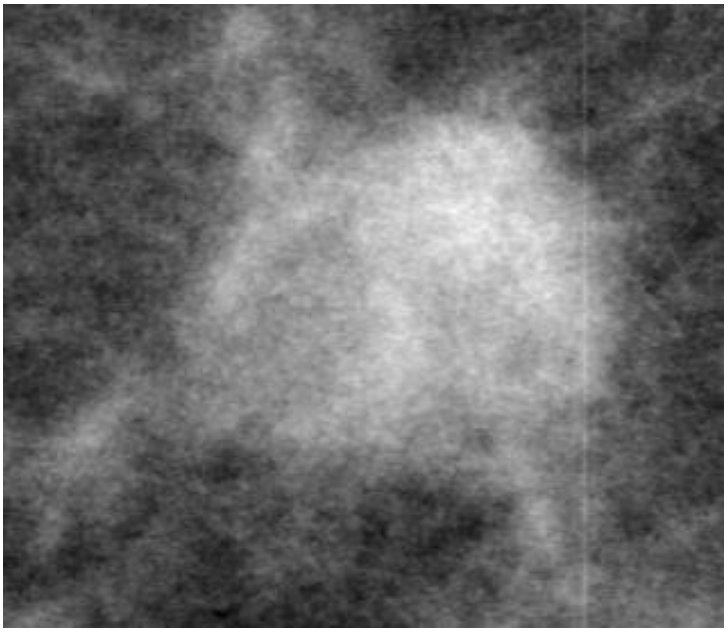

Figura 2. Imagem de mamografia classificada como MALIGNA

Fonte: https://www.kaggle.com/datasets/awsaf49/cbis-ddsm-breast-cancer-image-dataset. Acesso em: 13 ago. 2025.

Fora interpretações equivocadas que profissionais possam ter ao analisar imagens mamográficas, causando atraso no diagnóstico, há os casos normais difíceis de interpretar, que mesmo que sejam classificações benignas, causam dúvidas e confusões entre os médicos. Esses casos são caracterizados pelo tecido mamário denso que pode ter densidade semelhante a uma massa maligna, causando baixos níveis de sensibilidade nestes casos [Giess, Frost e Birdwell 2012].

Muitos desses casos que não ganham diagnósticos imediatos causam uma classificação BI-RADS 0, que significa inconclusão sobre as imagens, necessitando de exames complementares para certificar a saúde da paciente.

Em casos em que o médico realiza o diagnóstico de forma que resulte em um falso resultado, no entanto em uma próxima sessão se depara com um tumor avançado, se dá o nome de "câncer intervalar", onde na primeira sessão não é diagnosticado corretamente o câncer por confusão médica causada pela má qualidade de imagem (que também é responsabilidade do médico), e na sessão seguinte se depara com um câncer avançado.

Segundo pesquisa feita por Giess, Frost e Birdwell [2012], é dito que quando o câncer é visível na primeira sessão, porém não diagnosticado pelo médico devido a dúvida ou aparição benigna pode expor o responsável ao risco legal de negligência médica.

Além disso, de acordo com o Código de Ética Médica (art. 1, Capítulo III) "**É vedado ao médico:** Causar dano ao paciente, por ação ou omissão, caracterizável como imperícia, imprudência ou negligência" [Conselho Federal de Medicina 2019].

No âmbito desta pesquisa, a rede desenvolvida realizará a classificação de imagens apenas entre "benigno" e "maligno", servindo como guia assistente dos médicos operadores da tecnologia, para classificar corretamente entre as 7 categorias conhecidas do BI-RADS, reduzindo o quanto for possível atingir uma classificação BI-RADS 0, resultando em inconclusão. Assim, com um assistente inteligente, será possível reduzir a quantidade de casos em que os radiologistas caiam em situações duvidosas e negligenciáveis por falta de convicção do diagnóstico.

2.2. Redes Neurais e Conjuntos de Dados

Para a realização deste trabalho, foi escolhido realizar o aperfeiçoamento de um trabalho previamente realizado por Shabaan [2025], utilizando as arquiteturas CNN customizada e uma DenseNet121 propostas por ele. Esse aperfeiçoamento foi feito com a integração do *dataset* proposto no trabalho e a utilização das estratégias de tratamentos de dados propostas. As estratégias escolhidas foram pensadas especificamente para classificação de imagens médicas, de formato DICOM (*Digital Imaging and Communications in Medicine*).

Para desenvolvimento da rede, foi utilizada a aplicação Jupyter Notebook com a linguagem Python utilizando bibliotecas, sendo as principais Keras, Tensorflow e SKLearn para criação, validação e treinamento da rede, e as bibliotecas CV2, Matplotlib, Numpy, OS, Pandas e Shutil para pré-processamento e tratamento dos dados do *dataset*.

A arquitetura de Rede Neural Convolucional foi criada com a intenção de espelhar o comportamento e a estrutura do cérebro humano, utilizando suas camadas de neurônios para captar e utilizar padrões como bordas, texturas e formas para classificação ou detecção de objetos [Ferreira 2024]. É composta por três conjuntos de camadas essenciais:

1. **Camada Convolucional:** Detecta padrões e aplica os filtros criados pelos padrões nas imagens a serem classificadas;
2. **Camada de *Pooling*:** Reduz as dimensões das imagens para evitar variações excepcionais nas amostras, tornando a rede mais robusta;

3. **Camada Totalmente Conectada:** Classifica a amostra final após o processamento das camadas anteriores.

Desta forma com a crescente progressão do uso de IA para análise de imagens médicas, a arquitetura CNN e as suas variáveis ganham um alto destaque para essas atividades retornando resultados já considerados válidos e com potencial de melhora [Rajpurkar *et al*. 2022].

Portanto foram utilizadas duas redes como amostras para testes e decisão sobre qual seria escolhida analisando seus resultados de treino e validação para esta atividade, sendo as redes uma CNN Customizada criada no trabalho de Shabaan [2025] e uma DenseNet121.

2.2.1. CNN Customizada

A CNN customizada tem uma arquitetura profunda, com diversas camadas e um número grande de unidades por camada. Dentre elas são usadas camadas convolucionais comuns, e outros tipos de camadas convolucionais pensados para eficiência e desempenho na etapa convolucional.

Juntamente de camadas convolucionais 2D padrão, foram utilizadas camadas convolucionais 2D separáveis, que dividem o processo de convolução em duas etapas a fim de acelerar o processo e deixar a rede mais leve. É explicado cientificamente que [Ferreira 2024] as convoluções separáveis trabalham aplicando a convolução em duas etapas, primeiro aplicando as convoluções separadas para cada canal de entrada (etapa de *depthwise convolution*) e depois se usa convoluções em ponto final para combinar as características extraídas dos filtros (etapa de *pointwise convolution*), assim reduzindo o número de parâmetros nas camadas convolucionais.

Além disso, esta rede utiliza uma camada de média global de *pooling* para achatar os valores dos filtros para a camada totalmente conectada, sendo utilizada pela mesma justificativa do uso das convoluções separáveis, redução de parâmetros e leveza da rede. Esta camada faz uma média global de todos os valores dos filtros das camadas, achatando os valores em um vetor unidimensional para prosseguir nas camadas totalmente conectadas.

2.2.2. DenseNet121

A DenseNet121 é uma arquitetura pré-treinada com 121 camadas, que utiliza os filtros de camadas anteriores em todas as suas camadas posteriores, reaproveitando todos os filtros em camadas mais profundas da rede. Essa estratégia auxilia a rede no problema do gradiente desvanecente pela alta propagação de informações entre as camadas, assim também tornando-a mais eficiente em várias aplicações.

Esta rede é comumente utilizada em aplicações de classificações na área da medicina e saúde em geral, se destacando em questão de precisão das demais redes. Em trabalho relacionado de classificação de câncer de mama (neste caso de imagens histopatológicas) feito [Potsangbam e Devi 2024], sua precisão utilizando DenseNet121 superou as demais redes utilizadas em seu experimento, chegando em até 96.5% de precisão.

Dentro desta DenseNet121, foram adicionadas mais camadas totalmente conectadas ao final delas para realizarem o aprendizado e a classificação com maior precisão, aprofundando a rede e buscando alcançar o percentual de precisão esperado para este trabalho.

2.2.3. Tratamento do dataset

O dataset utilizado neste trabalho [Awsaf49 2021] foi montado com diversas pastas, onde cada pasta possui de uma a duas imagens, a primeira com uma imagem mamográfica e a segunda com uma imagem preta com um foco de atenção branco em alguma posição da imagem, representando um foco de atenção para realização de detecção e classificação. Dado o escopo do projeto de realizar apenas a classificação de imagens, as imagens com foco de atenção que tinham objetivo de auxiliar a detecção foram removidas do *dataset* final utilizado.

Além dos registros de imagens, também foram salvos no dataset arquivos de extensão .csv, com metadados de cada imagem pertencente ao dataset, tornando os dois recursos correlatos como uma imagem de formato DICOM. Destes arquivos .csv foram extraídos dados de 2 colunas, a coluna "*pathology*" indicando o tipo de patologia (dividida em BENIGN, BENIGN_WITHOUT_CALLBACK e MALIGNANT) e a coluna "*cropped image file path*" contendo o caminho parcial do arquivo de imagem relacionado.

Tendo esta informação, o dataset foi dividido da forma como está descrita na Figura 3 utilizando um módulo de divisão de arquivos separado do Notebook utilizado no treinamento da rede, a fim de organização do código. A divisão foi feita com uma pasta de teste armazenando os arquivos para teste, e uma pasta de treino dividida em subpastas com pastas nomeadas com as classificações, cada imagem na sua devida classificação sendo os dois tipos de benignos juntos em uma classificação só. Esta pasta de treino foi dividida para validação durante o processamento do treino.

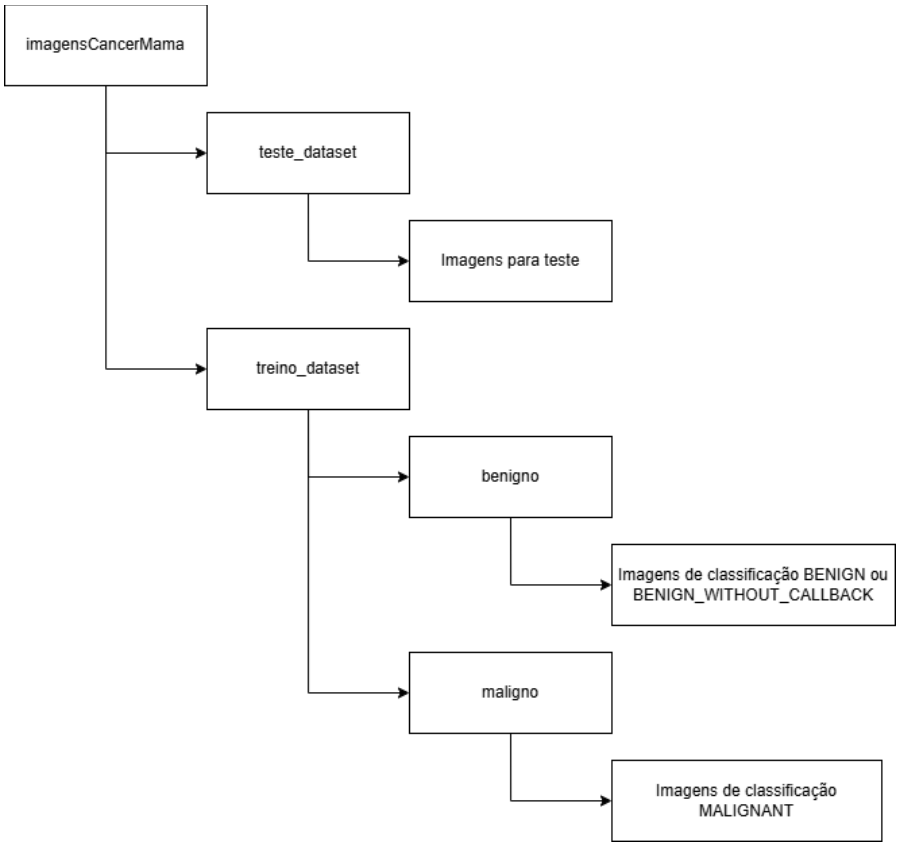

Figura 3. Estrutura de pastas final das imagens do *dataset*

Fonte: Produzido pelo autor.

2.2.4. Pré-processamento das imagens

Antes da etapa de treinamento, foi feito um pré-processamento nas imagens a fim de destacar as calcificações e lesões detectáveis nas imagens, assim melhorando a precisão. Como estratégia para esse melhoramento, foi aplicado CLAHE (Contrast Limited Adaptive Histogram Equalization) nas imagens, realçando locais embaçados e diminuindo o ruído nas imagens.

CLAHE é um algoritmo de pré-processamento utilizado para melhoramento do contraste local da imagem, melhorando a qualidade da imagem e realçando estruturas [Paixão 2023]. Este algoritmo é aplicado em imagens em escala de cinza apenas, então para aplicá-la nas imagens do *dataset* foi necessário realizar esta conversão como passo inicial do pré-processamento, assim posteriormente aplicado o algoritmo voltando a escala RGB.

O algoritmo CLAHE resulta em uma imagem com maior contraste e destaque nas regiões mais claras da imagem, ou neste caso, nas partes mais elevadas da mama, que podem ser causados por algum tumor ou entre as outras causas citadas anteriormente no artigo. A Figura 4 destaca muito bem a diferença, mostrando a imagem pós-aplicação com maior contraste e nitidez. Por ser um algoritmo altamente utilizado em ambas as áreas abordadas neste artigo, era crucial seu uso para o melhoramento do trabalho final.

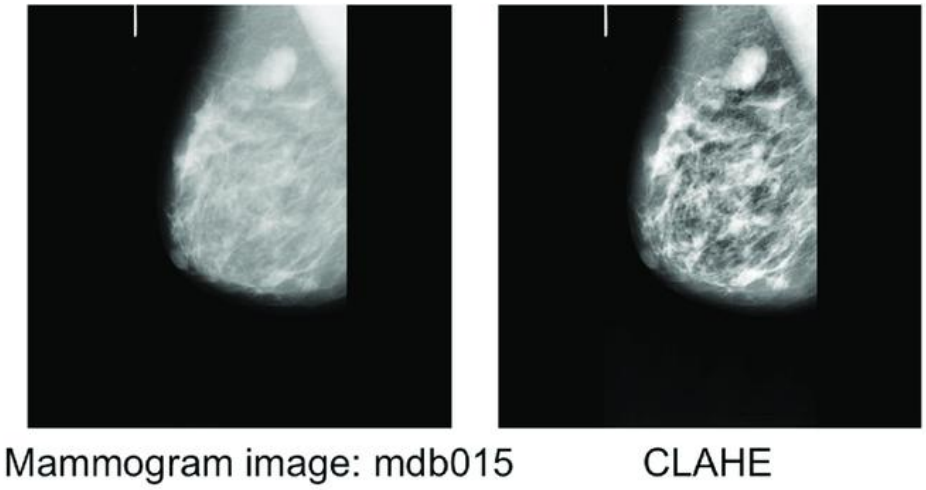

Figura 4. Imagem de mamografia antes e depois de aplicar CLAHE

Fonte: https://www.researchgate.net/figure/mage-enhancement-using-CLAHE_fig1_323313031. Acesso em: 21 nov. 2025.

3. Materiais e métodos

Para realização do trabalho, foi feita uma pesquisa com temas relacionados a tecnologia para a área da saúde, focada no escopo de mamografias, para que primeiro seja entendido o atual processo de análise de imagem e diagnóstico realizado apenas com a análise dos profissionais, sem utilização de nenhuma tecnologia auxiliar para classificação. A busca foi realizada utilizando diversas pesquisas relacionadas com os tópicos “principais processos para diagnóstico de câncer de mama” e “uso de tecnologia para análise de classificação de mamografias”.

As pesquisas foram realizadas majoritariamente na base científica da PubMed e da Biblioteca Virtual de Saúde (BVS), utilizando palavras-chave relacionadas com ambas as áreas estudadas, como “CNN”, “Mamografia”, “Rede Neural”, “Classificação de Imagens”, “Diagnóstico Precoce”, “Deep Learning” e “Câncer de Mama”.

Após entender o problema em questão, foram realizadas mais pesquisas agora focando no lado tecnológico em relação à solução proposta pelo trabalho em questão, para aprender sobre soluções relacionadas e aplicá-las como forma de aprendizado para inicialização do trabalho proposto. Nas pesquisas foram utilizados termos relacionados a tecnologia proposta, como “Redes Neurais Convolucionais”, “IA” e “classificação e detecção de imagens”.

As pesquisas foram realizadas através do indexador Google Acadêmico e das bases científicas citadas anteriormente, com foco em artigos no intervalo de data de 2020 até 2025, com uma tolerância para artigos fora do intervalo a depender das fontes e dos dados pesquisados, levando em conta a evolução da pesquisa desde quando foi publicado até os dias atuais.

Ao encerramento das pesquisas iniciais, foi-se a busca de um *dataset* para a realização do treinamento, validação e testes do modelo ainda não criado. Para a procura, foi visitado o site de repositório de *datasets* Kaggle, onde foi encontrado um trabalho relacionado a pesquisa feito por Shabaan [2025], com um trabalho incompleto de classificação de câncer de mama. Este trabalho foi utilizado a fins comparativos na coleta de resultados com diferentes dados, modelos e tecnologias para tratamento de dados, integrando o *dataset* proposto para a sua pesquisa [Awsaf49 2021] e o tratamento de imagens para as amostras.

O desenvolvimento foi feito em uma máquina com GPU integrada para melhor performance em treinamento, utilizando a IDE Visual Studio Code para programação da rede e outros utilitários referentes ao treinamento, validação e testes das diferentes redes utilizadas, ao tratamento de imagens e ao desempacotamento do *dataset* escolhido. Foi escolhido ambiente Linux e Jupyter Notebook para integração de bibliotecas Python que permitem alocação de memória para GPU, assim tornando o treinamento mais potente em questão de tempo esperado para conclusão.

Após primeira tentativa com a rede CNN customizada proposta pelo trabalho comparado, foi notado que a rede estava aprendendo, porém com alto nível de Overfitting durante o treinamento. Isso foi ocorrido devido à pouca profundidade oferecida pela rede criada e a utilização de dados sintéticos que não condiziam com imagens reais para o propósito da rede. Portanto foram adaptados pré-processamentos para imagens médicas pesquisadas através de códigos feitos por outros pesquisadores e o uso do *dataset* proposto em pesquisas, no entanto também não foi suficiente para a rede começar a aprender.

Então, foi decidido a utilização das redes pré-treinadas do trabalho relacionado, sendo elas a DenseNet121 e a EfficientNetB3. A partir destas redes foram realizados os experimentos com ambas, no entanto a EfficientNetB3 não apresentou os resultados esperados devido a sua baixa performance para o treinamento, tomando mais tempo do que o esperado para completá-lo. Já a DenseNet121, conteve resultados mais significativos para classificação de imagens de mamografias, sendo a escolhida para utilizar no trabalho juntamente da CNN Customizada.

O experimento com a CNN Customizada não rendeu bons resultados devido à falta de profundidade encontrada na rede, pelo contrário, o uso da DenseNet121 foi muito mais proveitoso por ser uma rede pré-treinada e com muito mais profundidade de camadas, podendo reconhecer padrões mais complexos.

Agora com todos os tratamentos para imagens médicas e a utilização de uma rede altamente profunda, o experimento chegou a um resultado positivo após análise das métricas resultantes do treinamento e do teste, mesmo que não tenha alcançado exatamente o objetivo definido para este trabalho.

4. Métricas

Foram recuperadas métricas focadas em análise de acertos e erros em cenários benignos e malignos, com o objetivo de compreender sua porcentagem de acertos em ambas as classificações e focada na análise de falsos positivos e negativos que podem ocorrer através de seu treinamento, assim delimitando seu desempenho em uma situação real, se assim após análise for concluído de que se pode entrar em uso real.

A avaliação dos resultados foi feita baseada em métricas recuperadas em tempo de treinamento, em comparação com trabalhos relacionados de desenvolvimento de redes neurais para classificação binária de câncer de mama.

4.1. Matriz de confusão

A matriz de confusão é de onde são extraídas todas as métricas de classificação do treinamento, contendo informações cruciais para entendimento dos diferentes acertos e erros possíveis dentro da classificação, como Verdadeiro Negativo (VN), Falso Positivo (FP), Falso Negativo (FN) e Verdadeiro Positivo (VP).

Verdadeiro Negativo é o resultado da classificação obtida e esperada serem “Benigno”, Falso Positivo é o resultado da classificação obtida ser “Maligno” enquanto a classificação esperada é “Benigno”, Falso Negativo é o resultado da classificação obtida ser “Benigno” enquanto a classificação esperada é “Maligno” e Verdadeiro Positivo é o resultado da classificação obtida e esperada serem “Maligno”.

A matriz de confusão é criada com dados recuperados através dos testes, utilizando o modelo treinado para classificar entre uma amostra de testes dividida entre as classificações. Esta amostra de testes contou com 378 imagens de mamografias, contando com 231 imagens de classificação Benigna e 147 imagens de classificação Maligna.

Ao calcular a matriz de confusão do experimento do trabalho, com os resultados das diferentes possibilidades da matriz, é alcançada as tabelas das Figuras 5 e 6, para a rede CNN Customizada e para a DenseNet121, respectivamente:

Classificação obtida / Classificação esperada	Benigno	Maligno
Benigno	(VN) 190	(FP) 41
Maligno	(FN) 91	(VP) 56

Figura 5. Matriz de confusão utilizando CNN Customizada

Fonte: Produzido pelo autor.

Classificação obtida / Classificação esperada	Benigno	Maligno
Benigno	(VN) 168	(FP) 63
Maligno	(FN) 47	(VP) 100

Figura 6. Matriz de confusão utilizando DenseNet121

Fonte: Produzido pelo autor.

Através destes 4 dados informando a quantidade de cada classificação alcançada, é possível calcular as demais métricas através de fórmulas matemáticas variadas a depender da métrica a ser descoberta.

4.2. *Accuracy*

Accuracy (Acurácia) indica a porcentagem de acertos nas previsões, sendo uma métrica crucial para entender e analisar o desempenho da rede treinada. Esta métrica é calculada comparando os resultados verdadeiros com a quantidade total de resultados realizando uma fração da soma dos resultados Verdadeiro Positivo e Verdadeiro Negativo com a soma de todos os resultados da matriz, como demonstra a equação abaixo:

$$\frac{VP + VN}{VP + VN + FP + FN}$$

4.3. *Loss*

Loss (Função de perda) é a métrica inversamente proporcional a métrica de *Accuracy*, sua função mede a diferença entre as previsões do modelo e os resultados reais esperados.

Existem diversas funções de perda aptas de se utilizar no treinamento de uma rede, dentro deste treinamento devido a sua classificação ser binária, foi utilizada a função de Entropia Cruzada Binária (*Binary Cross-Entropy*), representada pela equação abaixo, sendo y a classificação esperada para a amostra representada por 0 ou 1 e p a probabilidade da classificação ser Maligna:

$$-[y \log(p) + (1 - y) \log(1 - p)]$$

4.4. *Precision*

Precision (Precisão) indica apenas a porcentagem de acertos nos casos positivos do conjunto de testes, neste caso nos casos classificados como maligno, assim conseguindo medir a quantidade de verdadeiros e falsos positivos em relação aos casos positivos totais calculando a fração dos resultados Verdadeiro Positivo com a soma dos resultados Verdadeiro Positivo e Falso Positivo, como é visto na equação abaixo:

$$\frac{VP}{VP + FP}$$

4.5. *Recall*

Recall (Sensibilidade) indica a porcentagem de Verdadeiros Positivos acertados dentre todos os casos previstos para essa classificação, assim medindo a sensibilidade da rede de se detectar e classificar um caso verdadeiro. Para isso é utilizada a equação abaixo que calcula a fração dos resultados Verdadeiro Positivo com a soma dos resultados Verdadeiro Positivo e Falso Negativo:

$$\frac{VP}{VP + FN}$$

Há uma semelhança muito alta com a métrica de Precisão, porém com uma diferença importante, Precisão mede o acerto de Verdadeiro Positivo dentre todas as classificações Positivas, seja Verdadeiro Positivo ou Falso Positivo, enquanto a Sensibilidade mede o acerto de Verdadeiro Positivo dentre todas as classificações previstas para serem Verdadeiro Positivo.

4.6. AUC

AUC (*Area Under the Curve*) mede a área sob a curva ROC (*Receiver Operating Characteristic*), indicando a probabilidade de um exemplo ser classificado como Positivo acima de Negativo. Essa métrica é feita baseada na curva ROC, que é composto pela métrica de Sensibilidade como eixo Y e pela fórmula abaixo representando a porcentagem de Falsos Positivos acertados dentre todos os casos previstos para essa classificação como Eixo X. A fórmula abaixo calcula a fração dos resultados Falso Positivo com a soma dos resultados Falso Positivo e Verdadeiro Negativo:

$$\frac{FP}{FP + VN}$$

5. Resultados

Após realização de experimentos e treinamentos incluindo o *dataset* proposto para o trabalho e o tratamento das imagens, bons resultados para a pesquisa foram alcançados, chegando ao objetivo almejado com o desenvolvimento da rede. Para chegar a este resultado, foi utilizado o treinamento com 1318 amostras para treino, divididos com 80% para treinamento e 20% para validação. O treino foi realizado em 50 épocas, com *call-backs* usados para melhorar o desempenho e a confiabilidade do treinamento. Todo o desenvolvimento do código de construção e treinamento das redes fica disponível através do GitHub.

Foi realizado o treinamento com os dados utilizados pelo autor do trabalho inicial com as redes propostas. O que difere o experimento realizado neste trabalho do que foi realizado previamente pelo trabalho em comparação, foi a utilização do *dataset* proposto para realizar o treinamento e o uso do pré-processamento das imagens com CLAHE.

Levando o trabalho realizado anteriormente como comparação, como não foi utilizado nenhum *dataset*, foram utilizadas imagens geradas sinteticamente para treinamento, que não refletem exatamente o conteúdo de uma imagem real de uma mamografia como se nota na Figura 7 abaixo:

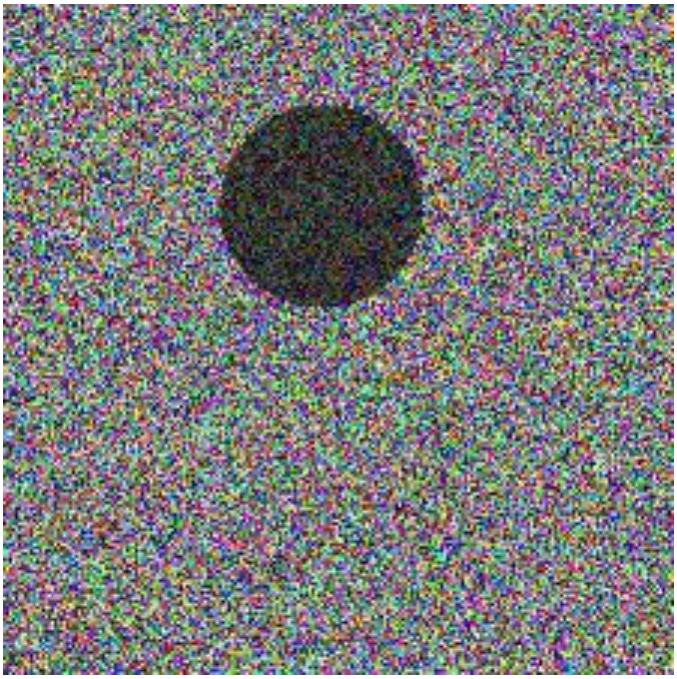

Figura 7. Exemplo de imagem gerada sinteticamente para treinamento das redes

Fonte: Produzido pelo autor.

Utilizando essas imagens para o treinamento da rede, foram alcançados os resultados expostos nos gráficos das figuras 8 e 9, sendo referentes as redes de CNN Customizada e a DenseNet121 respectivamente. Em ambos os gráficos, são detectados bons resultados de treinamento, porém alguns indicativos de Overfitting em Precisão e Sensibilidade, onde seu desempenho em treinamento e validação acabam por se opor.

Na Figura 8-a, é visto que a métrica de acurácia atingiu valores máximos em treino e validação a partir da época 20 em diante, com uma oscilação quase que inversamente proporcional na época 15. Juntando essa informação com o gráfico de função de perda na Figura 8-b, o qual apresenta resultado de queda brusca das mesmas formas que o gráfico de acurácia, é visto indicadores de que a rede aprendeu sobre os elementos de forma muito veloz, algo que não é comum em etapas de treinamento de redes neurais. Esse aprendizado veloz ocorre, pois, as amostras sintéticas utilizadas são muito discrepantes em suas classificações benigno e maligno, e por não haver um grande conjunto de características para serem analisadas, como é visto na Figura 7.

Analisando as Figuras 8-c, 8-d e 8-e, representando os gráficos com as métricas de Precisão, Sensibilidade e AUC respectivamente, nota-se que os valores deixam de oscilar a partir da época 20 como ocorreram com as métricas de Acurácia e Perda, porém com uma diferença pontual em seus valores, visto que os resultados de validação estão muito abaixo em relação aos resultados de treinamento. Essas informações combinadas com as informações de validação dos dois gráficos de Acurácia e Perda não se relacionam logicamente, pois Acurácia mede a precisão geral da rede, que resultou em 100%, enquanto os resultados de validação analisados apresentam valores muito abaixo do que é esperado observando os resultados de Acurácia, o que sugere pela análise que a apuração dos resultados foi realizada de forma equivocada.

Nos gráficos da Figura 9, é visto uma oscilação similar com a ocorrida nos gráficos da Figura 8, porém acontecendo mais cedo por volta da época 10, parando de oscilar também da época em diante, caracterizando um aprendizado mais veloz para esse tipo de rede. A Figura 9-a, representando os resultados de Acurácia da DenseNet121, teve resultado final semelhante ao da CNN Customizada, apenas alterando na época de sua oscilação em validação, assim como o gráfico de Perda na Figura 9-b, porém este com uma curva descendente mais gradual.

Observando os gráficos nas Figuras 9-c e 9-d representando os resultados das métricas de Precisão e Sensibilidade respectivamente, é visto o mesmo problema encontrado nos gráficos das Figuras 8-c e 8-d, onde seus resultados de treinamento e validação andam quase que proporcionalmente invertidos, tornando a sua análise em cima da análise da Acurácia inconsistente pelos mesmos motivos previamente citados. No entanto houve grande diferença ao observar os resultados da Figura 9-e em comparação com a Figura 8-e que representam os resultados das métricas de AUC de cada rede, visto que na Figura 9-e houve resultados consistentes para treinamento e validação com oscilações até a época 20.

Dadas as análises dos gráficos resultantes do experimento do trabalho relacionado, é visto que utilizando dados sintéticos e sem o tratamento com CLAHE almejado na implementação do autor, as redes obtiveram resultados pouco confiáveis ao considerar a disparidade ocorrente em resultados de treino e validação das métricas, o que leva à fortes indicativos de que as redes aprenderam sobre aquele conjunto de amostras de treinamento específico ao invés de coletar características e filtros para aplicar em outras imagens fora do conjunto de treinamento.

A CNN Customizada tem um desempenho consideravelmente pior devido a sua falta de profundidade na rede, no entanto, independentemente dos resultados apresentados pelas métricas, não são resultados proveitosos para o projeto proposto e para a prática real de seu uso, devido a sua amostra de treino utilizada não condizer também com as amostras reais que devem ser utilizadas.

Neste trabalho relacionado não foi possível coletar a curvatura AUC em cima da curva ROC do treinamento, apenas a métrica isolada AUC de cada rede, que também apresentaram oscilações entre os dados de treinamento e validação.

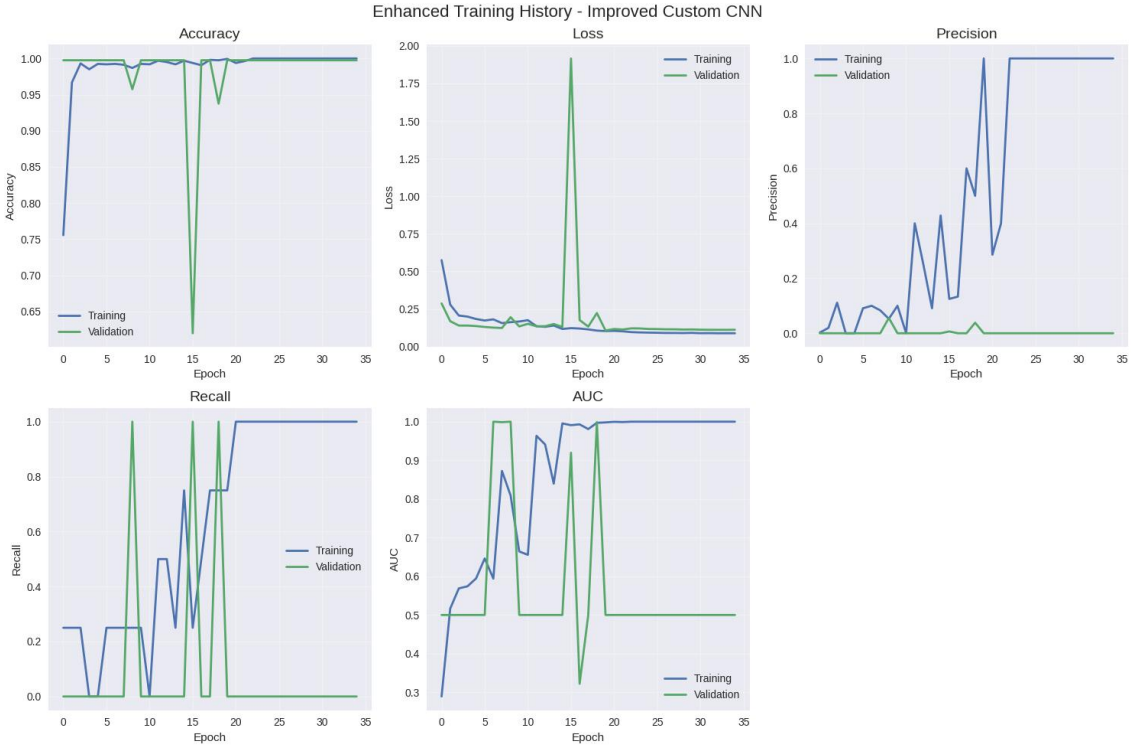

Figura 8. Métricas alcançadas com CNN Customizada e dados sintéticos do autor

Fonte: https://www.kaggle.com/code/ahmedfekryshabaan/new-brest-cancer-classification-project. Acesso em: 24 set. 2025.

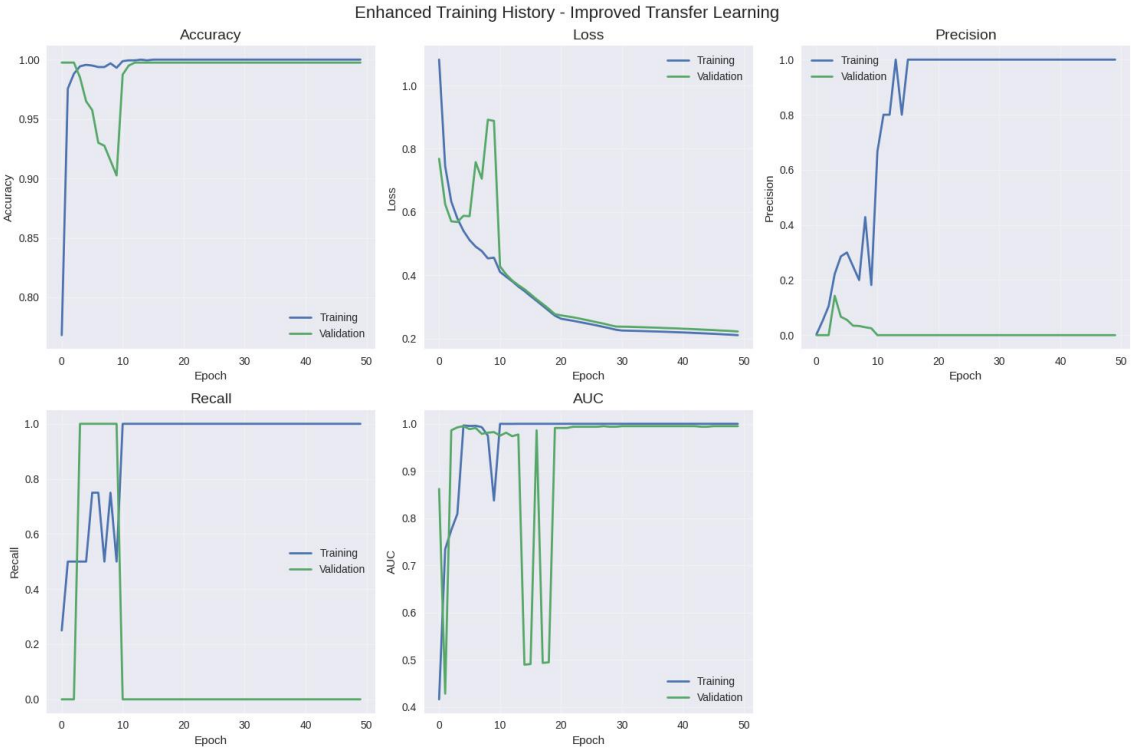

Figura 9. Métricas alcançadas com DenseNet121 e dados sintéticos do autor

Fonte: https://www.kaggle.com/code/ahmedfekryshabaan/new-brest-cancer-classification-project. Acesso em: 24 set. 2025.

Utilizando as mesmas redes utilizadas para o treinamento, foram adicionados o *dataset* proposto para o treinamento da rede, com o tratamento dos dados utilizando pré-processamento com CLAHE para tornar as imagens mais nítidas nas áreas de maior relevo, representando regiões de maior densidade mamária.

Utilizando estes recursos a mais para se aproximar mais do cenário real de seu uso, foram alcançados bons resultados como demonstram os gráficos nas Figuras 10-a e 10-b, representando as métricas de Acurácia e Perda respectivamente para a CNN Customizada. Em sua Acurácia e Perda, é visto um distanciamento de seus resultados de treino e validação com o passar das épocas, apresentando grandes oscilações em validação desde o início do treinamento. No entanto, nestas métricas são observados resultados mais realistas levando em conta a baixa profundidade da rede utilizada, que ainda assim apresentou indícios de aprendizado, porém com resultados de validação bem inversos ao que se alcança em treinamento.

Observando os gráficos nas Figuras 10-c e 10-d representando as métricas de Precisão e Sensibilidade, é visto que os resultados de treino foram regulares em uma zona aleatória de acerto, perto dos 50% durante todo o treinamento. Já em validação, as figuras apresentaram resultados bem distintos, que, ao analisar a matriz de confusão em conjunto com os resultados dos gráficos, leva a conclusão de que a rede está classificando muito mais casos como negativos do que positivos. Observa-se também que, houve mais classificações Verdadeiro Positivo do que Falso Positivo, tornando a Precisão alta, mas em contrapartida houve quase que o dobro de classificações Falso Negativo em relação à Verdadeiro Positivo, tornando a rede CNN Customizada pouco sensível a casos Positivos.

Ao analisar o gráfico na Figura 10-e representando a métrica AUC, é observado uma grande similaridade nos resultados de treino e validação, que leva a rede como uma rede concisa em relação aos resultados, apesar das oscilações ocorridas nas primeiras épocas. Devido ao alcance de até aproximadamente 75% em treino e validação, torna o experimento da rede com bons resultados, ainda com potencial de melhora ao torná-la mais profunda.

Analisando agora os resultados dos gráficos 11-a e 11-b da Figura 11, representando as métricas de Acurácia e Perda da DenseNet121 com *dataset* e pré-processamento de imagens, é visto resultados significativos em comparação com todos os outros analisados anteriormente, apresentando uma melhora de complexidade logarítmica em ambas as métricas, tanto em treinamento quanto em validação. A métrica de Acurácia apresenta algumas oscilações grandes até a época 30 aproximadamente, enquanto a Perda deixa de oscilar na época 10, apresentando semelhança entre os resultados esperados e obtidos.

As métricas de Precisão e Sensibilidade representadas pelos gráficos 11-c e 11-d respectivamente apresentaram maiores oscilações em validação até a época 30, no entanto, após esta época, foram alcançados bons resultados em questão de valores tanto em treino quanto em validação em ambas as métricas, ainda que oscilantes. Com as duas métricas com bons resultados, é analisado que a rede classifica bem os casos Positivos, que consta como um grande diferencial da rede na área da sociedade onde deve ser utilizada.

A figura 11-e, representando a métrica AUC, alcançou resultados muito bons, chegando ao valor final próximo a 90% em treino e validação. Isso significa uma excelente capacidade de classificações corretas para esta rede. Ao aplicar estes resultados em cima da curvatura ROC, na Figura 12, é visto uma curva acentuada para o canto superior esquerdo, com uma maior acentuação para a DenseNet121 representada pela curva vermelha, com mais distância da linha

neutra de 45° representando a aleatoriedade das classificações. Estes resultados alcançaram um pico próximo de 80% em sua proximidade com o canto superior esquerdo.

Ao analisar todos os resultados é visto que, mesmo com o algoritmo de parada antecipada para interromper o treinamento se o algoritmo indicasse que a rede não aprenderia mais do que o ponto atual, todos os treinamentos concluíram o treinamento com as 50 épocas, indicando que a rede ainda teria mais margem para aprendizado mesmo após as 50 épocas.

Ainda que não tenha sido alcançada a porcentagem de >= 90% esperada, ainda são bons resultados analisando as outras métricas, principalmente observando os resultados da DenseNet121, pois tendo uma alta porcentagem de Precisão, Sensibilidade e AUC, é indicado poucos casos de Falsos Negativos dentro da rede, que é a classificação mais crítica para se ocorrer dentro do objetivo da rede, como também é indicado na sua matriz de confusão.

A CNN Customizada ainda apresentou sinais de *Overfitting* em sua função de perda, porém já se esperava resultados nesta faixa apesar de melhores, comparados aos experimentos com imagens sintéticas. Os resultados continuam devido à falta de profundidade por parte da rede.

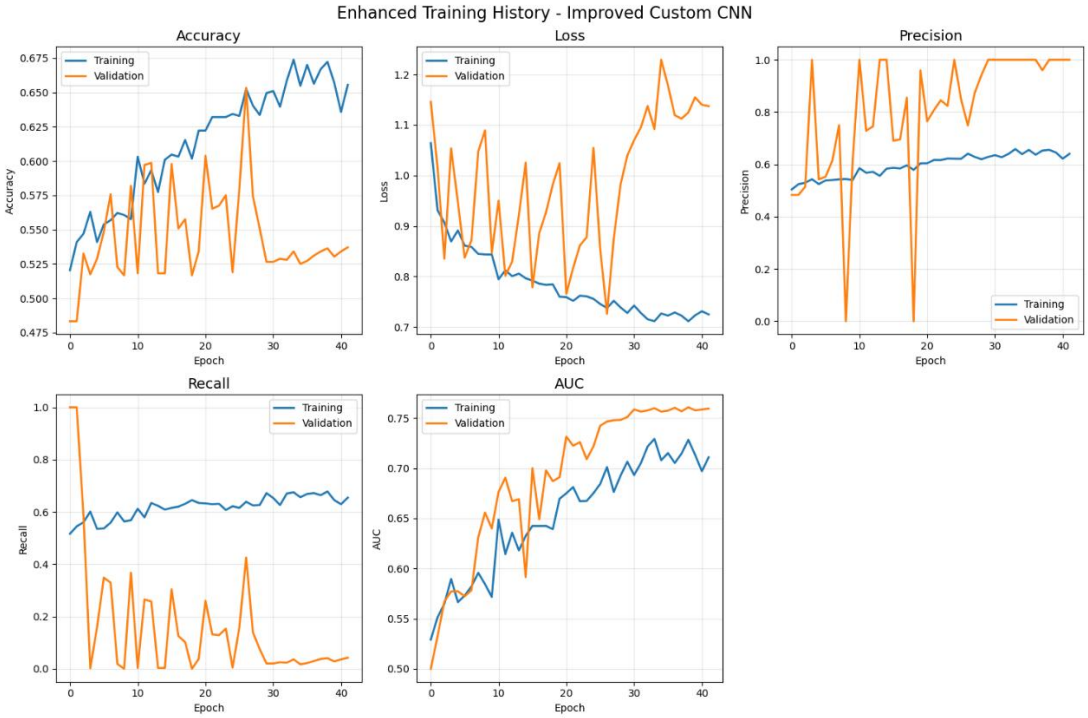

Figura 10. Métricas alcançadas com CNN Customizada e dataset com imagens reais

Fonte: Produzido pelo autor.

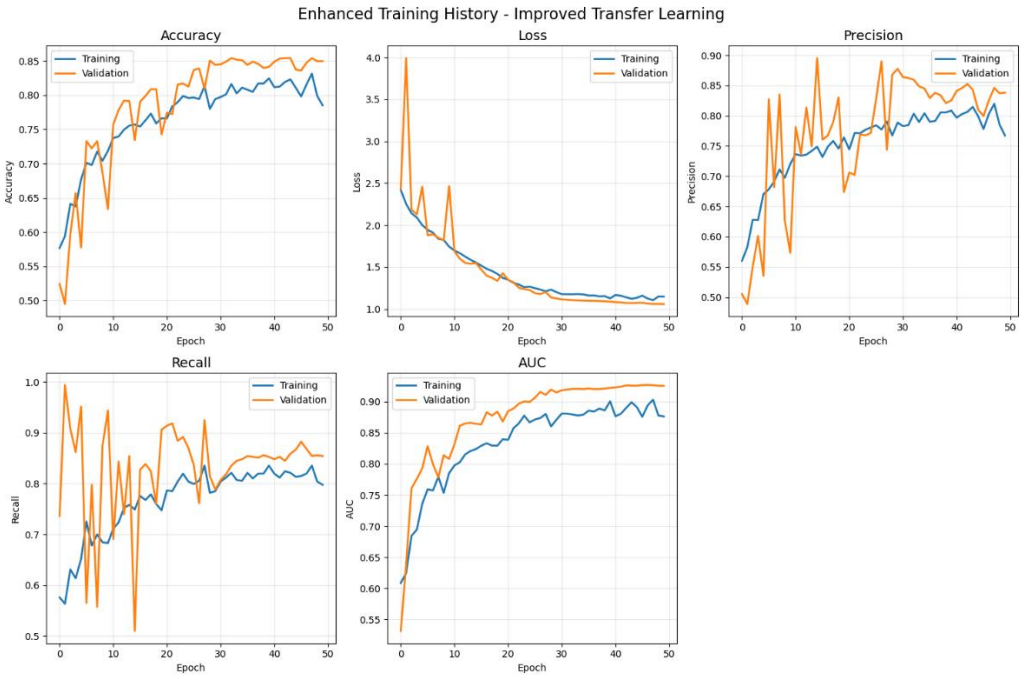

Figura 11. Métricas alcançadas com DenseNet121 e dataset com imagens reais

Fonte: Produzido pelo autor.

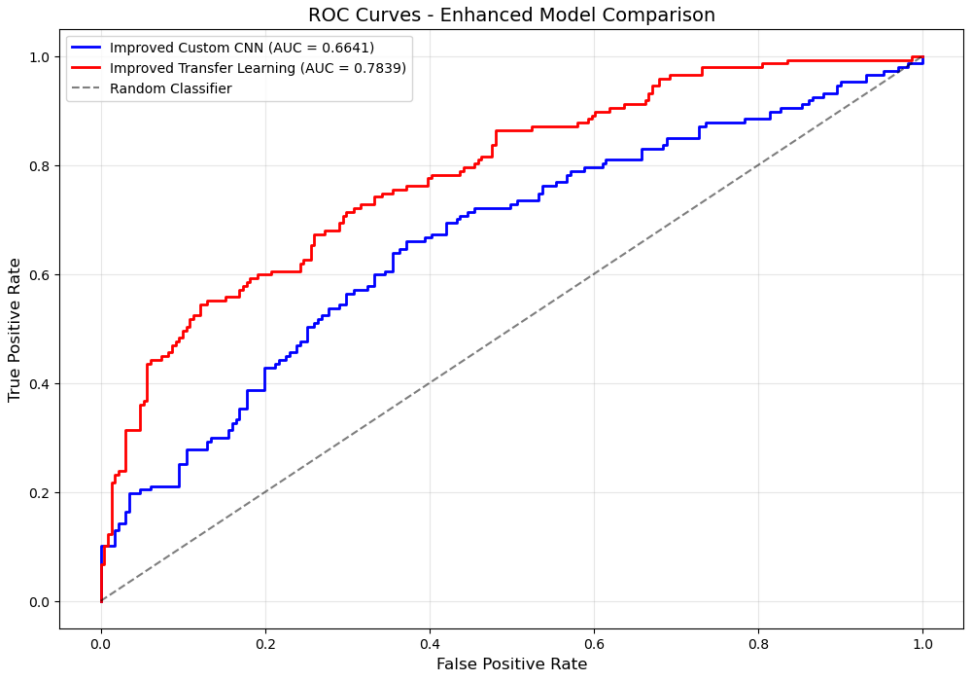

Figura 12. AUC em cima da curvatura ROC

Fonte: Produzido pelo autor.

5. Conclusão

O câncer de mama é uma doença de potencial letal que tem o impacto de alterar completamente o estilo de vida das mulheres que o contêm, dando mais atenção à saúde da paciente como forma de evitar o avanço da doença e preservar a vida das pessoas que desenvolvem este problema. A principal forma de combater este problema hoje é através do diagnóstico precoce feito pelos médicos especialistas, porém, este diagnóstico se torna um desafio em certos casos complexos onde a análise precisa de mais atenção para que não sejam cometidos enganos no diagnóstico.

Observado o problema causado pelos casos complexos na análise profissional, foi proposta uma solução tecnológica para servir como assistente para os profissionais, realizando classificação de imagens de mamografias entre Benigno e Maligno, através do desenvolvimento de uma Rede Neural Convolucional treinada utilizando um *dataset* de imagens de mamografias online e um pré-processamento com CLAHE para tornar as imagens mais nítidas, e alcançar resultados melhores do que como seria com imagens sem esse tratamento.

Após experimentos, foram alcançados resultados melhores em comparação com redes idênticas, porém que não utilizaram o *dataset* utilizado nem o pré-processamento aplicado nas imagens, chegando a resultados significativos em questão de Acurácia, Precisão, Sensibilidade e AUC, onde todas as métricas alcançaram valor aproximado ou superior de 80%. Com isso, é visto que foi desenvolvida uma rede sensível aos tipos de casos Positivos para assim evitar classificações Falso Negativo.

Para este trabalho, é almejado como melhora o aprofundamento da rede DenseNet121 utilizada com mais camadas totalmente conectadas, ao considerar que a rede obteve os melhores resultados dos experimentos, e se almeja experimentar os treinamentos com mais épocas, visto que o algoritmo de parada antecipada não interrompeu o treinamento

Referências

AWSAF49. **CBIS-DDSM: Breast Cancer Image Dataset** [conjunto de dados], Versão 1, 2021. Disponível em: https://www.kaggle.com/datasets/awsaf49/cbis-ddsm-breast-cancer-image-dataset. Acesso em: 09 jun. 2025.

BARAZI, Hassana; GUNDURU, Mounika. **Mammography BI RADS Grading**. In: StatPearls [Internet]. *StatPearls Publishing*, 2023. Acesso em: 23 jan. 2026.

BERNARDES, Nicole Blanco *et al*. **Câncer de mama x diagnóstico/breast cancer x diagnosis**. ID on line. Revista de psicologia, v. 13, n. 44, p. 877-885, 2019.

CONSELHO FEDERAL DE MEDICINA (CFM). **Resolução CFM nº 2.217, de 27 de setembro de 2018 (publicada em 6 de novembro de 2019)**. Aprova o Código de Ética Médica. *Diário Oficial da União*, Brasília, DF, 06 nov. 2019, Seção I, p. 179–188. Disponível em: https://portal.cfm.org.br/images/PDF/cem2019.pdf. Acesso em: 8 nov. 2025.

DE SOUZA, Marcio Costa et al. **Itinerários terapêuticos produzidos por mulheres na busca pelo acesso ao diagnóstico e cuidado no câncer de mama.** *Saúde em Redes*, v. 8, n. 3, p. 239-251, 2022.

FERREIRA, Verner Rafael. **FiberNet:** um modelo de rede neural convolucional simples e eficiente. Orientadora: Dr. Anne Magaly de Paula Canuto. 2024. 124f. Tese (Doutorado em Ciência da Computação) - Centro de Ciências Exatas e da Terra, Universidade Federal do Rio Grande do Norte, Natal, 2024. Disponível em: https://repositorio.ufrn.br/server/api/core/bitstreams/93a29903-6252-4c70-9c8f-493b21d7c0ea/content. Acesso em: 21 nov. 2025

GIESS, C. S.; FROST, E. P.; BIRDWELL, R. L. **Difficulties and errors in diagnosis of breast neoplasms**. *Seminars in Ultrasound, CT and MRI* , v. 33, n. 4, p. 288-299, ago. 2012. Disponível em: https://doi.org/10.1053/j.sult.2012.01.007. Acesso em: 2 nov. 2025.

GUERREIRO, Aline Angélica Peres *et al*. **Integrando inteligência artificial à mamografia:** uma abordagem complementar no diagnóstico do câncer de mama. Revista Ibero-Americana de Humanidades, Ciências e Educação, v. 10, n. 5, p. 479-485, 2024.

PAIXÃO, Júlia Sousa. **Análise da qualidade das imagens mamográficas a partir de transformações de equalização de histograma e de aplicação de métricas de qualidade.** 2023. 45 f. Trabalho de Conclusão de Curso (Graduação em Física Médica) - Universidade Federal de Uberlândia, Uberlândia, 2023. Disponível em: https://repositorio.ufu.br/handle/123456789/40929. Acesso em 23 jan. 2026.

POTSANGBAM, Jacinta; DEVI, Salam Shuleenda. **Classification of breast cancer histopathological images using transfer learning with DenseNet121**. *Procedia Computer Science*, v. 235, p. 1990-1997, 2024. Acesso em: 21 nov. 2025.

RAJPURKAR, Pranav et al. **AI in health and medicine.** *Nature medicine*, v. 28, n. 1, p. 31-38, 2022. Acesso em: 23 jan. 2026.

RICHARD, A *et al*. **Recover your smile:** Effects of a beauty care intervention on depressive symptoms, quality of life, and self-esteem in patients with early breast cancer. *Psycho-Oncology* , v. 28, n. 2, p. 401-407, fev. 2019. Disponível em: https://doi.org/10.1002/pon.4957. Acesso em: 1 nov. 2025.

SHABAAN, Ahmed Fekry. **New Brest Cancer Classification Project**. Versão 1. 2025. Disponível em: https://www.kaggle.com/code/ahmedfekryshabaan/new-brest-cancer-classification-project. Acesso em: 24 set. 2025.

SILVA, A. R. da; NICOLELLA, A. C.; PAZELLO, E. T. **Análise do efeito da alocação de mamógrafo sobre indicadores de saúde da mulher**. *Cadernos de Saúde Pública*, Rio de Janeiro, v. 40, n. 7, p. e00220122, 2024.

TADESSE, G. F.; TEGAW, E. M.; ABDISA, E. K. **Diagnostic performance of mammography and ultrasound in breast cancer:** a systematic review and meta-analysis. *Journal of Ultrasound* , v. 26, n. 2, p. 355-367, jun. 2023. Disponível em: https://doi.org/10.1007/s40477-022-00755-3. Acesso em: 1 nov. 2025.

Agradecimentos

À minha mãe por tudo que ela tem feito por mim e muito mais durante a minha vida, que independente do momento que passou nunca deixou de me apoiar e ficar ao meu lado durante todas as etapas da minha vida, é a base de tudo que acredito e defendo moralmente hoje que me fez chegar até onde estou. Ao meu pai pelo tanto que lutou e continua lutando pela nossa família para conquistarmos o que continuarmos conquistando, um homem que sempre demonstrou amar e defender aqueles que ama, meu maior exemplo de guerreiro e pai. Ao meu irmão pelo apoio e pelos recursos que me ofereceu no início do curso para estudos quando eu ainda não tinha meu computador próprio, tudo teria sido mais difícil sem a sua ajuda, obrigado por tudo. Aos meus melhores amigos vindos do ensino médio, Carlos, João e Juliana, que sempre me arrancaram as risadas mais sinceras e me entregaram os rolês mais esperados por mim. Obrigado por tudo que já fizeram e fazem por mim até hoje, são meu espelho de amizade verdadeira e duradoura e eu torço que alcancem tudo que almejam para as suas vidas, farei tudo que puder ao meu alcance para que isso ocorra.

Aos meus professores orientadores e coordenadores da bolsa, André, Fellipe (Felipão), Jorgiano e Marília, por me ensinarem a ser o profissional que eu sou hoje. Aos meus professores, orientador e coorientador, Robinson e Sales, por terem topado seguir essa jornada comigo. Aos meus grandes amigos e colegas de trabalho, Ana Maria, Débora, Ísis, Lívia, Maure, Ramon e Ryan, por tudo que me ensinaram em meu tempo trabalhando em conjunto. Aos meus companheiros de laboratório do LADES, os Ladeiros, por me aceitarem como parte da família e me entregarem uma amizade que espero durar muito tempo ainda. Às minhas amigas desde o início da faculdade, Débora e Ester, por todos os momentos que compartilhamos juntos dentro e fora do campus, desejo todas as melhores coisas do mundo para vocês. Aos meus companheiros de pelada toda sexta a noite, principalmente aos meus amigos de faculdade, Leonardo e Luiz Gustavo, espero continuar frequentando pelo tempo que der, cada jogo foi um espaço importante para manter minha mente no lugar e me concentrar nas minhas pesquisas. À minha amiga Lívia por cada evento extra faculdade que topou participar comigo ou que tenha me convidado a participar, espero que conquiste cada meta e desejo que compartilhou comigo, durante nossas conversas tarde da noite na faculdade e nas paradas de ônibus.